

Data Drift em um Modelo Seq2Seq para Predição de Trajetórias

Ivan Yamasaki¹[], Marcos Máximo²[], and Paulo Tasinaffo³[]

Instituto Tecnológico de Aeronáutica, SP, Brasil

Resumo Este artigo analisa *data drift* em um modelo *sequence-to-sequence* (seq2seq) para predição de trajetórias de robôs na RoboCup Small Size League (SSL). O modelo foi treinado com dados de 2019 e avaliado em temporadas posteriores, com foco em dois horizontes de predição. O objetivo é medir como o erro, resumido principalmente pelo *Average Displacement Error* (ADE), evolui ao longo do tempo, como essa evolução se compara a um benchmark baseado em filtro de Kalman e em que medida mudanças observáveis na dinâmica do jogo acompanham essa degradação.

Os resultados mostram aumento do erro absoluto do seq2seq nos anos posteriores ao treinamento, caracterizando perda de desempenho fora da distribuição original. Ao mesmo tempo, a vantagem relativa do seq2seq sobre o Kalman aumenta, sugerindo que ambos sofrem com a mudança temporal dos dados, mas o Kalman degrada mais rapidamente. Como análise complementar, o artigo emprega regressões OLS relacionando a variação do ADE com métricas de drift baseadas em Kolmogorov-Smirnov e Wasserstein, controlando efeitos fixos de ano. Essa etapa é interpretada como evidência exploratória de associação, e não como identificação causal.

Keywords: predição de trajetórias · seq2seq · data drift · RoboCup SSL · Kalman

1 Introdução

Predição de trajetórias é uma tarefa central em sistemas autônomos sujeitos a dinâmica rápida. Na RoboCup SSL, prever a movimentação futura dos robôs auxilia planejamento, posicionamento e tomada de decisão em tempo real.

Métodos baseados em filtro de Kalman [3] são tradicionais nesse problema por serem simples e baratos computacionalmente. No entanto, dependem de hipóteses cinemáticas restritivas, como dinâmica relativamente suave e bem descrita por modelos lineares locais. Em cenários com acelerações bruscas, mudanças rápidas de direção e estratégias cada vez mais complexas, essa modelagem tende a perder precisão. Além disso, esse tipo de benchmark cinemático não representa explicitamente intenções futuras, interações entre agentes ou ajustes táticos do jogo.

Modelos seq2seq oferecem maior flexibilidade para capturar dependências temporais mais ricas. Eles também podem aprender, de forma implícita, padrões recorrentes de ação futura a partir dos dados observados, sem precisar explicitar manualmente todas as regras de interação. Porém, melhor desempenho em um período específico não garante robustez temporal. Se a dinâmica do jogo muda ao longo das temporadas, um modelo treinado em dados antigos pode sofrer degradação ao ser aplicado em anos posteriores. Esse é precisamente o problema de *data drift* analisado neste trabalho.

O ponto de partida desta análise é o modelo seq2seq originalmente proposto por Lucas Steuernagel e Marcos Ricardo Omena de Albuquerque Máximo [1] para predição de trajetórias na SSL. Assim, a contribuição do presente artigo não está em introduzir uma nova arquitetura, mas em reavaliar temporalmente esse modelo de referência e investigar sua robustez fora do período de treino.

2 Objetivo

O objetivo do artigo é analisar a robustez temporal de um modelo seq2seq treinado com dados de 2019, considerando dois horizontes de predição, por meio de três perguntas principais:

- como o erro absoluto evolui ao longo do tempo em cada horizonte;
- como a diferença de desempenho entre seq2seq e Kalman evolui ao longo dos anos;
- se o aumento do erro acompanha métricas observáveis de drift nas variáveis cinemáticas.

3 Metodologia

A análise foi organizada em quatro etapas:

1. replicação do modelo seq2seq de referência;
2. avaliação anual do desempenho em temporadas posteriores;
3. comparação com o benchmark de Kalman;
4. análise estatística complementar da relação entre drift e aumento de erro.

A primeira etapa reproduz o modelo de referência de Steuernagel e Máximo [1] com a implementação utilizada neste projeto. Em particular, a entrada de cada passo temporal é composta por seis variáveis normalizadas: posição x, y , velocidade v_x, v_y e orientação codificada por $\sin(\psi)$ e $\cos(\psi)$. O treinamento usa uma separação fixa de validação de 10% dentro do conjunto de treino, *batch size* de 1024, otimizador Adam [4], *early stopping* e redução adaptativa da taxa de aprendizado. Esses detalhes são mantidos fixos para que a comparação temporal reflita mudanças na distribuição dos dados, e não mudanças no procedimento de ajuste.

A métrica principal é o *Average Displacement Error* (ADE), por resumir o desvio médio entre trajetória prevista e trajetória real ao longo do horizonte de predição. Formalmente, para N trajetórias e horizonte H ,

$$\text{ADE} = \frac{1}{NH} \sum_{i=1}^N \sum_{t=1}^H \|\hat{p}_{i,t} - p_{i,t}\|_2.$$

Os anos de 2020 e 2021 foram removidos da análise principal. O motivo é que esse período inclui uma ruptura estrutural relevante no campeonato, especialmente em 2021, quando houve forte mudança de regime. A exclusão evita misturar drift mais gradual com uma alteração exógena do ambiente competitivo.

Ao longo do artigo, os resultados são apresentados separadamente para os horizontes $30 \rightarrow 15$ e $60 \rightarrow 30$.

4 Arquitetura do modelo

O modelo utilizado neste trabalho segue uma arquitetura *sequence-to-sequence* do tipo *encoder-decoder* com mecanismo de atenção aditiva, em linha com o trabalho de Steuernagel e Máximo [1] e com o mecanismo de atenção popularizado por Bahdanau, Cho e Bengio [2]. Na implementação reproduzida aqui, o encoder é uma LSTM com 128 unidades e o decoder opera de forma auto-regressiva a partir da última velocidade observada na janela passada.

Considere uma janela passada de comprimento n e um horizonte futuro de comprimento m :

$$X \in \mathbb{R}^{n \times d_x}, \quad Y \in \mathbb{R}^{m \times d_y}$$

O encoder LSTM produz estados:

$$H = [h_1, h_2, \dots, h_n]$$

A atenção é definida por:

$$e_{j,k} = v^\top \tanh(W_1 s_{j-1} + W_2 h_k)$$

$$\alpha_{j,k} = \frac{\exp(e_{j,k})}{\sum_{\ell=1}^n \exp(e_{j,\ell})}$$

$$z_j = \sum_{k=1}^n \alpha_{j,k} h_k$$

O decoder gera:

$$\hat{q}_j = W_o s_j + b_o$$

A função de perda é:

$$\mathcal{L} = 100 \cdot (\text{MSE} + \text{MAE})$$

Na configuração usada neste projeto, o decoder opera sem *teacher forcing*: a primeira entrada do decoder é a última velocidade observada, e os passos seguintes reutilizam as saídas previamente previstas. Além disso, o pipeline de treinamento parametriza o alvo no espaço de velocidades incrementais normalizadas ($d\mathbf{v}$) e reconstrói a trajetória futura em posição a partir do último estado observado. Esse detalhe é importante porque deixa claro que o modelo não prevê posições diretamente, mas sim uma dinâmica futura que depois é acumulada no espaço de estados.

5 Desempenho do seq2seq ao longo do tempo

A Figura 1 apresenta a evolução do ADE do seq2seq ao longo dos anos, separadamente para os dois horizontes analisados. Em ambos os casos, o padrão geral após 2019 é de aumento do erro, ainda que com magnitudes distintas.




Figura 1: Evolução do ADE do seq2seq ao longo dos anos, separada por horizonte de predição.

Esse resultado é consistente com a hipótese de *data drift*: o modelo foi treinado em uma distribuição associada a 2019 e perde desempenho ao ser aplicado a temporadas posteriores. A separação por horizonte também mostra que a deterioração não é necessariamente idêntica entre tarefas de predição mais curtas e mais longas, o que reforça a utilidade de analisar os dois cenários de forma independente.

A leitura desses gráficos deve ser sobretudo descritiva. O objetivo aqui é estabelecer o fato básico de que há degradação temporal do erro absoluto do modelo, e não ainda explicar seu mecanismo.

6 Comparação com o Kalman

A Figura 2 compara o ADE do seq2seq com o do filtro de Kalman ao longo dos anos, novamente separando os horizontes de predição. O resultado central é que o seq2seq permanece melhor do que o Kalman, mas a diferença entre os dois cresce nas temporadas mais recentes.




Figura2: Comparação de ADE entre Seq2Seq e Kalman ao longo dos anos, separada por horizonte.

Essa evidência precisa ser interpretada com cuidado. O aumento da vantagem relativa do seq2seq não significa que ele esteja estável. A seção anterior já mostrou que o erro absoluto do próprio seq2seq também cresce. A conclusão correta é que ambos os métodos sofrem degradação temporal, mas o Kalman parece mais sensível à mudança de distribuição.

A Figura 3 reforça essa interpretação ao mostrar o aumento percentual do ADE de cada método em relação a 2019, para cada horizonte. Em praticamente todos os anos analisados, o crescimento percentual do erro do Kalman supera o do seq2seq.

Esse ponto é importante porque desloca a leitura do artigo. O resultado principal não é simplesmente que o seq2seq vence o Kalman, mas que ele parece degradar menos quando a dinâmica do jogo se afasta do ambiente de treino. Em termos práticos, isso sugere maior robustez relativa do modelo neural, ainda que sem eliminar o problema de drift.




Figura 3: Aumento percentual do ADE em relação a 2019 para Seq2Seq e Kalman, separado por horizonte.

7 Drift nas variáveis cinemáticas

Para investigar possíveis mecanismos por trás da deterioração do desempenho, a Figura 4 apresenta a evolução anual de métricas de drift nas variáveis de velocidade, aceleração e giro. Foram utilizadas duas famílias de medidas: estatísticas baseadas em Kolmogorov–Smirnov (KS) e distâncias de Wasserstein (WD).




Figura 4: Evolução anual das métricas KS e WD para variáveis cinemáticas.

Esses gráficos não provam, por si sós, que o drift observado nas variáveis cinemáticas cause o aumento do ADE. Ainda assim, eles são informativos porque mostram que a degradação de desempenho ocorre junto de mudanças mensuráveis na distribuição das variáveis que descrevem a dinâmica do jogo.

Em particular, velocidade e aceleração apresentam sinais mais claros de alteração nos anos posteriores. Isso é compatível com a hipótese de que a SSL passou a exibir partidas mais rápidas, com transições mais agressivas e movimentos menos aderentes às hipóteses simplificadoras do benchmark clássico. A variável de giro também é relevante, mas o padrão visual parece menos dominante do que o observado para velocidade e aceleração.

8 Análise por regressão OLS

Como complemento à análise descritiva, foram ajustados os seguintes modelos:

$$\Delta ADE \sim ks_speed + ks_accel + ks_turn + C(year), \quad (1)$$

$$\Delta ADE \sim wd_speed + wd_accel + wd_turn + C(year). \quad (2)$$

Aqui, ΔADE representa a variação do ADE em relação ao ano-base de 2019, enquanto $C(year)$ introduz efeitos fixos por ano. O papel dessa regressão não é identificar causalidade nem decompor de forma definitiva a origem do erro. A função da OLS neste artigo é mais modesta: verificar se métricas observáveis de drift mantêm associação com a variação do ADE após controlar diferenças médias entre anos.

A Figura 5 resume os resultados dessa análise.




Figura 5: Resumo visual da análise OLS relacionando ΔADE com métricas de drift.

A interpretação dessa seção exige cautela por pelo menos três motivos. Primeiro, a análise trabalha com baixa granularidade temporal, o que limita o poder inferencial. Segundo, drift e ano compartilham forte estrutura temporal, de modo que parte da variação carregada pelas métricas KS e WD também é capturada pelos efeitos fixos anuais. Terceiro, as próprias métricas de drift podem apresentar correlação entre si, especialmente quando descrevem mudanças semelhantes nas distribuições cinemáticas.

Apesar dessas limitações, a OLS ainda é útil como exercício exploratório. Coeficientes positivos para *ks_speed*, *ks_accel*, *ks_turn* ou seus equivalentes em WD indicam que maior drift nessas variáveis tende a vir acompanhado de maior aumento de erro. Assim, a regressão não fecha a questão, mas reforça a leitura qualitativa dos gráficos anteriores: a deterioração do ADE não parece puramente aleatória, e sim associada a mudanças observáveis na dinâmica do jogo.

Em outras palavras, esta seção deve ser lida como um ponto de partida para uma agenda de inferência mais forte, e não como sua etapa final. Um próximo passo natural é migrar da análise anual agregada para uma base mais granular, por partida, janela temporal ou bloco de jogadas, permitindo observar variação intra-ano e distinguir melhor o efeito de tempo do efeito do drift mensurado. Com essa granularidade maior, uma estratégia promissora seria modelar explicitamente a exposição ao drift como “tratamento” contínuo e estudar sua associação com o erro por meio de um desenho causal mais estruturado, com efeitos fixos e testes de robustez temporal.

9 Discussão

Os resultados do artigo apontam para três mensagens principais.

A primeira é a mais sólida: o seq2seq sofre degradação temporal de desempenho. O aumento do ADE em anos posteriores ao treinamento é consistente com presença de *data drift*.

A segunda também é robusta: a vantagem relativa do seq2seq sobre o Kalman cresce ao longo do tempo. Isso sugere que o benchmark clássico é ainda mais sensível às mudanças de regime da SSL. Logo, robustez relativa maior não implica ausência de drift; implica apenas deterioração menos acentuada.

A terceira mensagem é mais moderada: parte dessa variação do erro parece acompanhar medidas observáveis de drift nas variáveis cinemáticas. Essa conclusão é sustentada pela combinação entre leitura visual das séries de KS e WD e pela análise OLS, mas ainda deve ser entendida como evidência sugestiva, não conclusiva.

Essa distinção é importante para a interpretação do artigo. A contribuição principal do trabalho é empírica e diagnóstica: mostrar que o desempenho fora do período de treino se deteriora e que essa deterioração é consistente com mudança de distribuição. A parte econométrica entra como apoio analítico, ajudando a organizar hipóteses sobre o mecanismo do drift, mas sem ainda resolvê-las de forma causal.

Também é importante delimitar com clareza o escopo da contribuição frente ao artigo de Steuernagel e Máximo [1]. O presente trabalho herda desse artigo o núcleo arquitetural do preditor neural e o benchmark comparativo com Kalman. O avanço aqui está em deslocar a pergunta de pesquisa: em vez de perguntar apenas se o seq2seq supera o benchmark em um recorte fixo, pergunta-se como esse ganho evolui quando a distribuição temporal dos dados se afasta do ambiente de treino.

Nesse sentido, uma agenda natural de continuidade seria investigar diretamente se o drift afeta mais o seq2seq ou o Kalman em magnitude marginal. Em vez de modelar apenas o erro absoluto, uma extensão interessante é usar como variável dependente a diferença $ADE^{Kalman} - ADE^{Seq2Seq}$ ou sua razão relativa. Isso permitiria estudar não apenas se há drift, mas em que contextos ele amplia mais a vantagem comparativa do modelo neural sobre o benchmark clássico.

10 Conclusão

Este artigo analisou a estabilidade temporal de um modelo seq2seq para predição de trajetórias na RoboCup SSL. Os resultados mostram que o modelo perde desempenho em anos posteriores ao treinamento, caracterizando drift. Também mostram que o aumento relativo do erro do Kalman é maior, o que amplia a vantagem comparativa do seq2seq em temporadas mais recentes.

Portanto, a conclusão principal é dupla. Primeiro, há evidência clara de degradação temporal no seq2seq. Segundo, o Kalman parece sofrer ainda mais com a mudança temporal da distribuição dos dados. As métricas KS e WD, juntamente com a análise OLS, reforçam a interpretação de que o aumento do erro acompanha mudanças mensuráveis na dinâmica observada das partidas.

Ao mesmo tempo, o artigo delimita o alcance dessa inferência. A regressão OLS deve ser lida como análise exploratória complementar, útil para orientar hipóteses e próximos testes, mas insuficiente para sustentar causalidade. O avanço natural a partir daqui é construir uma análise com maior granularidade temporal e desenho inferencial mais forte, capaz de avaliar de forma mais direta como a exposição ao drift afeta o erro de predição dos diferentes modelos. Em termos de crédito científico, o presente estudo se apoia diretamente na linha inaugurada por Lucas Steuernagel e Marcos Máximo [1], estendendo-a do problema de desempenho pontual para o problema de estabilidade temporal.

Referências

1. Steuernagel, L., Máximo, M. R. O. A.: Trajectory Prediction for SSL Robots Using Seq2seq Neural Networks. In: Eguchi, A., Lau, N., Paetzel-Prüsmann, M., Wani-chanon, T. (eds.) RoboCup 2022: Robot World Cup XXV. LNCS, vol. 13561, pp. 27–38. Springer, Cham (2023). doi:10.1007/978-3-031-28469-4_4
2. Bahdanau, D., Cho, K., Bengio, Y.: Neural Machine Translation by Jointly Learning to Align and Translate. In: 3rd International Conference on Learning Representations (ICLR) (2015)
3. Kalman, R. E.: A New Approach to Linear Filtering and Prediction Problems. *Journal of Basic Engineering* **82**(1), 35–45 (1960)
4. Kingma, D. P., Ba, J.: Adam: A Method for Stochastic Optimization. In: 3rd International Conference on Learning Representations (ICLR) (2015)