

Data Drift in a Seq2Seq Model for SSL Robot Trajectory Prediction

Ivan G. Yamasaki¹[0009-0000-4776-134X], Marcos R. O. A. Máximo¹[0000-0003-2944-4476], and Paulo M. Tasinaffo¹[0000-0001-7069-8430]

Aeronautics Institute of Technology, São José dos Campos, Brazil

Resumo Este artigo analisa *data drift* em um modelo *sequence-to-sequence* (seq2seq) de predição de trajetórias na RoboCup Small Size League (SSL), treinado com dados de 2019 e avaliado nas temporadas de 2021 a 2025. O erro absoluto (*Average Displacement Error*, ADE) cresce de forma persistente após o treino — excessos de até +0,73 mm em 2022–2025, além do salto de +3,05 mm na edição virtual de 2021 (horizonte 30→15) —, enquanto o benchmark de Kalman degrada ainda mais — a vantagem relativa do modelo neural aumenta sob drift. A origem da degradação é quantificada por *importance weighting* via LSIF, com robustez verificada por truncamento de pesos e pela transformação de razão relativa, e validada por um *classifier two-sample test* independente: 59–72% do excesso de ADE é explicável por *covariate shift*, com a aceleração de cauda (`accel_p99`) como dimensão dominante.

Na adaptação — restrita a 2019 (regime antigo) e 2022–2025 (dados novos), com a edição virtual de 2021 excluída como *outlier* —, o *catastrophic forgetting* cai de 0,82 para 0,46 (`cat_ratio`) com ajuste conservador; um sweep de λ ao longo de 8 ordens de grandeza mostra que a proteção vem da taxa de aprendizado baixa, não da regularização EWC. Por fim, a calibração de detectores online sobre o stream de 288 k trajetórias, validada por holdout 2-fold por jogos, produz um detector operacional (ADWIN sobre o erro, com pré-processamento z-robusto): FAR₂₀₁₉ de 0,04–0,13/1k fora da amostra, cobertura de 9/10 anos-fold e latência de 0,2–1,5 jogo. O vetor dominante do drift fornece ainda um canal de vigilância *model-free* (`accel_p95`) que antecipa o alarme de erro em 8/10 anos-fold, e a conjunção erro^aceleração zera os falsos alarmes observados.

Keywords: predição de trajetórias · seq2seq · data drift · detecção de drift · RoboCup SSL · Kalman

1 Introdução

Predição de trajetórias é uma tarefa central em sistemas autônomos sujeitos a dinâmica rápida. Na RoboCup SSL, prever a movimentação futura dos robôs auxilia planejamento, posicionamento e tomada de decisão em tempo real.

O filtro de Kalman [3] é o benchmark tradicional nesse problema por ser simples e barato, mas depende de hipóteses cinemáticas restritivas — dinâmica

suave, bem descrita por modelos lineares locais. Modelos seq2seq capturam dependências temporais mais ricas e aprendem padrões de ação futura diretamente dos dados. Porém, melhor desempenho em um período específico não garante robustez temporal: se a dinâmica do jogo muda entre temporadas, um modelo treinado em dados antigos degrada. Esse é o problema de *data drift* analisado aqui.

O ponto de partida é o modelo seq2seq de Steuernagel e Máximo [1] para predição de trajetórias na SSL. A contribuição deste artigo não é uma nova arquitetura, mas a reavaliação temporal desse modelo de referência, organizada em quatro perguntas:

1. como o erro evolui ao longo das temporadas, em dois horizontes de predição, e como essa evolução se compara ao benchmark de Kalman;
2. que fração da degradação é explicável por *covariate shift* (mudança na distribuição de entrada) e qual dimensão cinemática a domina;
3. se a adaptação leve (fine-tuning seletivo, EWC [15]) recupera desempenho sem esquecimento catastrófico;
4. se é possível operar um detector online de drift com taxa de falsos alarmes, cobertura e latência adequadas para acionar retreino.

2 Trabalhos relacionados

Predição de trajetórias. A linha de pesquisa evoluiu do *social pooling* entre LSTMs vizinhas (Social-LSTM [16]) para grafos dinâmicos com variáveis latentes multimodais (Trajectron++ [17]), Transformers *agent-aware* (AgentFormer [18]) e modelos de difusão (MID [19]). No domínio SSL, Steuernagel e Máximo [1] aplicaram a arquitetura seq2seq com atenção e os mesmos horizontes aqui estudados — é o baseline direto deste trabalho. Essa literatura avalia modelos em recortes fixos; a estabilidade *temporal* entre temporadas, foco deste artigo, permanece pouco explorada.

Drift e detecção online. Gama et al. [10] distinguem *virtual drift* (mudança em $p(x)$) de *real drift* (mudança em $p(y|x)$), e os detectores dividem-se entre *error-based* — ADWIN [12], Page-Hinkley [13] — e *data-based*, como KSWIN [14]. Lu et al. [11] apontam a calibração da taxa de falsos alarmes como requisito central de confiabilidade — exatamente a lacuna que a Seção 9 fecha por busca em grade sobre o stream real, complementada por validação de latência e de robustez à dependência serial.

Covariate shift. A estimação direta da razão de densidades via LSIF/KLIEP [5, 7, 6] permite corrigir covariate shift sem retreinar; o RuLSIF [8] é a variante de razão relativa com pesos limitados, e o *classifier two-sample test* [9] oferece um detector de shift independente de forma. Este artigo usa o LSIF como estimador principal, verifica sua robustez diretamente — truncamento de pesos e transformação de razão relativa (Seção 7) — e emprega o classifier como validação independente.

3 Metodologia

Dados. São usados registros oficiais de partidas dos campeonatos mundiais de 2019 a 2025 (2020 excluído por ausência de campeonato presencial): 6 jogos por ano, 36 jogos no total, capturados a 60 Hz, todos da Divisão A. O ano de 2021 corresponde à edição pós-pandêmica realizada virtualmente (partidas em simulação) e é mantido nas análises descritivas por representar o salto de distribuição mais severo (+3,05 mm de excesso de ADE) — com a ressalva de que parte desse salto pode refletir a lacuna simulação–real, e não apenas drift orgânico da liga; por isso as análises por ano o sinalizam separadamente. Por essa mesma razão — por ser uma edição *virtual*, com distribuição de variáveis cinemáticas fora do padrão das temporadas presenciais e o maior deslocamento de covariate shift do período —, 2021 é tratado como *outlier* e **excluído da análise de adaptação** (Seção 8): consolidar o modelo tomando como referência uma temporada anômala e simulada contaminaria o regime antigo com uma distribuição que não representa o comportamento real da liga. Nessa análise, portanto, o regime antigo é apenas 2019 (o baseline presencial de treino) e os dados novos são 2022–2025. Como a composição da liga é constante nos dados, o excesso observado não é atribuível a mudança de divisão. Para as análises por trajetória, amostram-se 8 000 janelas por jogo, formando um stream temporalmente ordenado de 288 000 trajetórias (48 000 por ano). O baseline de 2019 usa *todos* os 6 jogos do ano: um *sweep* de sensibilidade mostra que, com apenas 1 jogo de referência, ADE_{2019} varia de 4,53 a 6,20 mm — o suficiente para inverter o sinal do excesso em 4 dos 5 anos — o que torna o baseline completo uma decisão metodológica crítica.¹

Etapas. A análise tem cinco etapas: (i) replicação do modelo de referência [1] (descrito na Seção 4); (ii) avaliação anual do erro e comparação com o benchmark de Kalman; (iii) quantificação do *covariate shift* por *importance weighting* (LSIF), com verificações de robustez e validação por *classifier two-sample test*; (iv) experimentos de adaptação (fine-tuning, EWC, replay e seleção dirigida pelo diagnóstico); (v) calibração sistemática de detectores online sobre o stream de ADE, com validação de latência, de robustez da taxa de falsos alarmes e de ensembles.

Na replicação, a entrada de cada passo temporal é composta por seis variáveis normalizadas: posição x, y , velocidade v_x, v_y e orientação $\sin(\psi), \cos(\psi)$. O treinamento usa validação fixa de 10 %, *batch size* 1024, otimizador Adam [4] com taxa de aprendizado inicial 10^{-3} (*clipnorm* 1,0), *early stopping* com paciência 8 e redução adaptativa da taxa de aprendizado — detalhes mantidos fixos para que a comparação temporal reflita mudanças nos dados, não no ajuste.

A métrica principal é o ADE. Para N trajetórias e horizonte H ,

$$ADE = \frac{1}{NH} \sum_{i=1}^N \sum_{t=1}^H \|\hat{p}_{i,t} - p_{i,t}\|_2, \quad (1)$$

¹ Código do pipeline e dados processados disponíveis mediante solicitação aos autores.

em que $\hat{p}_{i,t}$ é a posição prevista e $p_{i,t}$ a real. As análises descritivas reportam os horizontes $30 \rightarrow 15$ e $60 \rightarrow 30$; as análises de mecanismo e detecção usam o horizonte $30 \rightarrow 15$.

4 Arquitetura do modelo

O modelo segue a arquitetura *encoder-decoder* de Steuarnagel e Máximo [1]: encoder LSTM com 128 unidades, atenção aditiva de Bahdanau et al. [2] e decoder LSTM auto-regressivo, sem *teacher forcing* — a primeira entrada do decoder é a última velocidade observada e os passos seguintes reutilizam as saídas previstas. A cada passo do decoder, a atenção pondera os estados ocultos do encoder por *softmax* sobre escores aditivos, produzindo o vetor de contexto que alimenta a predição.

O treinamento minimiza a perda combinada

$$\mathcal{L} = 100 \cdot (\text{MSE} + \text{MAE}). \quad (2)$$

O fator 100 é um reescalonamento numérico herdado da implementação de referência [1]. Um detalhe relevante para a análise de drift: o alvo é parametrizado no espaço de velocidades incrementais normalizadas ($\mathbf{dv}$), e a trajetória futura em posição é reconstruída a partir do último estado observado. O modelo prevê, portanto, uma dinâmica futura acumulada no espaço de estados — o que o torna diretamente sensível a mudanças na distribuição de velocidades e acelerações.

Benchmark de Kalman. O comparador cinemático é o preditor de velocidade constante correspondente ao regime estacionário de um filtro de Kalman [3] com modelo CV: no espaço $\mathbf{dv}$, os incrementos de velocidade previstos são nulos — a velocidade é mantida no último valor observado e a posição é extrapolada linearmente. É determinístico, livre de parâmetros ajustáveis e idêntico em todos os anos, o que o torna uma referência fixa: qualquer degradação sua reflete exclusivamente mudança no comportamento dos robôs.

5 Degradação temporal do erro

A Figura 1 consolida os três fatos descritivos centrais.

(a) O seq2seq degrada fora da distribuição de treino. O ADE cresce em todos os anos pós-2019, com tendência de excesso crescente em 2022–2025 (+0,23 mm em 2022 $\rightarrow$ +0,73 mm em 2025, com 2024 próximo de zero, no horizonte 30 $\rightarrow$ 15). O ano de 2021 destoa (+67 %) porque acumula um fator de erro adicional: a edição foi realizada em simulação (Seção 3). O padrão se repete nos dois horizontes.

(b) O Kalman degrada mais. O crescimento percentual do erro do Kalman supera o do seq2seq em praticamente todos os anos. A leitura correta não é que o seq2seq esteja estável — seu erro absoluto também cresce — mas que o




Figura 1: Degradação temporal consolidada (cor = modelo; traço = horizonte). (a) ADE médio por ano: o seq2seq degrada após 2019, com excesso crescente em 2022–2025 e salto adicional na edição virtual de 2021; permanece muito abaixo do Kalman. (b) Aumento percentual do ADE em relação a 2019 por modelo e horizonte. (c) Razão p99/p50 do ADE por trajetória: o salto de 2021 é de cauda ($4,36 \rightarrow 4,94$); em 2022–2025 a razão fica abaixo do baseline (3,4–4,0), com o p50 subindo $\approx 25\%$ até 2025 e o p99 estável — a degradação gradual ocorre no corpo da distribuição.

benchmark cinemático é ainda mais sensível à mudança de regime: a vantagem comparativa do modelo neural *aumenta* sob drift.

(c) O regime novo entra pela cauda e depois se generaliza. A razão p99/p50 do seq2seq sobe apenas no salto de 2021 ($4,36 \rightarrow 4,94$), quando o modelo falha desproporcionalmente em uma cauda de trajetórias. Nos anos seguintes a razão cai abaixo do baseline (3,4–4,0): o p50 sobe $\approx 25\%$ até 2025 enquanto o p99 permanece estável — o comportamento que era raro torna-se comum, e a degradação gradual ocorre no corpo da distribuição. Isso é coerente com o covariate shift dominado por aceleração de cauda (*accel_p99*, Seção 7): a dinâmica agressiva que definia a cauda incorpora-se à distribuição típica das temporadas seguintes.

6 Drift nas variáveis cinemáticas

A Figura 2 examina se a degradação acompanha mudanças mensuráveis na distribuição das variáveis de velocidade, aceleração e giro, medidas por duas estatísticas independentes contra o baseline de 2019: Kolmogorov–Smirnov (KS) e distância de Wasserstein (WD).

Velocidade e aceleração mudam de forma clara e persistente nos anos pós-2019, com KS e WD concordando qualitativamente; o giro muda menos. No nível de jogo, o ADE cresce quase monotonicamente com a aceleração de cauda do jogo (*accel_p99*, painel c) — partidas mais agressivas são exatamente aquelas em que o modelo mais erra, independentemente do ano.

A Figura 3 sintetiza as associações: as correlações mais fortes com o ADE do seq2seq envolvem as features de aceleração de cauda (*accel_p90*, *accel_p99*),




Figura 2: Drift cinemático consolidado. (a) Estatística KS por ano contra o baseline 2019 (linhas = média anual; pontos = jogos): velocidade e aceleração mudam mais que giro. (b) Wasserstein indexada ao nível de 2019 (=1): as duas famílias de métricas concordam qualitativamente; a aceleração apresenta o maior deslocamento distribucional. (c) ADE médio por jogo contra `accel_p99` do jogo (reta de regressão com IC 95 % bootstrap): a associação é forte (Spearman $\rho = 0,86$) e consistente entre anos.

antecipando o resultado por feature da decomposição por *importance weighting* (Tabela 2). Essas associações são descritivas — a quantificação causal da fração do erro atribuível ao covariate shift é feita na Seção 7.

7 Quantificação do drift via importance weighting

Decomposição covariate vs. concept drift. A distribuição conjunta fatoriza-se como $p(x, y) = p(y|x)p(x)$ [10]. O *covariate shift* altera apenas $p(x)$ e pode ser corrigido por reponderação dos exemplos antigos, sem retrainar; o *concept drift* altera $p(y|x)$ e exige novos dados rotulados. Distinguir as componentes é o que justifica o *importance weighting* (IW): se o drift for majoritariamente covariate, a correção é barata.

LSIF e ADE ponderado. O LSIF (*Least-Squares Importance Fitting*) [5,7,6] estima diretamente a razão de densidades $\hat{w}(x) = p_{\text{alvo}}(x)/p_{2019}(x)$ como combinação de kernels gaussianos. O vetor $x \in \mathbb{R}^8$ reúne as features cinemáticas da janela observada de cada trajetória — média, p90 e p99 da velocidade e da aceleração, e média e p90 do giro —, com corte no percentil 99,5 do pool (estabiliza a cauda) e transformação $\log(1 + \cdot)$:

$$\min_{\alpha \geq 0} \frac{1}{2} \mathbb{E}_{p_{2019}}[\hat{w}(x)^2] - \mathbb{E}_{p_{\text{alvo}}}[\hat{w}(x)] + \lambda \|\alpha\|^2. \quad (3)$$

A estabilidade é diagnosticada pelo *Effective Sample Size* (ESS), definido como $(\sum_i \hat{w}_i)^2 / (n \sum_i \hat{w}_i^2)$, com regra prática $\text{ESS} > 0,5$ [6]. A partir dos pesos, definem-se o ADE ponderado e a fração recuperada do excesso:

$$\text{ADE}_{\text{IW}}(y) = \frac{\sum_i \hat{w}(x_i) e_i}{\sum_i \hat{w}(x_i)}, \quad \text{recovery}(y) = \frac{\text{ADE}_y - \text{ADE}_{\text{IW}}(y)}{\text{ADE}_y - \text{ADE}_{2019}} \times 100 \%. \quad (4)$$




Figura3: Correlação de Spearman entre o ADE por jogo e as features de drift (anos $\neq$ 2020/2021).

Recovery de 100 % indicaria drift puramente covariate; 0 %, concept drift puro.

Robustez do estimador e validação independente. A leitura quantitativa exige confiança no comportamento dos pesos, sobretudo sob caudas pesadas (`accel_p99`). Três verificações diretas sustentam o LSIF. (i) *Pesos limitados*: $\max_i \hat{w}_i \in [2,9; 4,4]$ em todos os anos; o ESS de 0,58–0,73 reflete a massa de pesos ≈ 0 atribuída ao regime novo — o mecanismo correto de reconstrução de 2019 —, e não pesos extremos (o top-1 % das trajetórias carrega apenas 3–4 % da massa). (ii) *Insensibilidade a truncamento*: um sweep de $\text{cap } c \in \{1,5, \dots, 50\}$ mostra que a recovery satura em $c \approx 3$ –5. (iii) *Insensibilidade à razão relativa*: aplicar aos pesos a transformação $\hat{w}/(\alpha\hat{w} + 1 - \alpha)$ do RuLSIF [8] ($\alpha=0,1$) mantém a recovery em 59–65 %. O RuLSIF ajustado diretamente foi testado e descartado: nesta configuração produz pesos quase uniformes ($\text{ESS} \geq 0,94$) e sub-responde (recovery 9–23 %) — artefato da regularização do ajuste, não do estimando, como as verificações (ii) e (iii) demonstram. A validação independente é o *classifier two-sample test* [9]: regressão logística que separa 2019 do ano-alvo, com cobertura $\text{cov} = \text{clip}(2(\text{AUC} - 0,5) \cdot 100, 0, 100)$. Os intervalos usam *block bootstrap* com bloco = jogo e denominador fixado no excesso observado — a razão por réplica degenera com 6 blocos quando o excesso é pequeno. A Tabela 1 consolida.

Leitura. A recovery LSIF situa-se em 59–72 % nos anos com excesso, com ICs que excluem zero em todos eles — e, mais forte, o limite inferior da correção

Tabela 1: Decomposição IW (LSIF) com block bootstrap por jogo ($n_{\text{boot}} = 2000$; $n_{\text{blocos}} = 6$ jogos/ano); ICs de recovery com denominador fixado no excesso observado. Baseline: $\text{ADE}_{2019} = 4,53$ mm; excesso = $\text{ADE}_y - \text{ADE}_{2019}$. ADE_{IW} é o ADE do ano reponderado para a distribuição de 2019; corr. = $\text{ADE}_y - \text{ADE}_{\text{IW}}$: o limite inferior é positivo em todos os anos com excesso. ESS $\in [0,58; 0,73]$. 2024 tem excesso negativo e é excluído da recovery. Classifier com $p < 10^{-3}$ por permutação em todos os anos. $^\dagger 2022$: excesso pequeno (0,23 mm) — a leitura percentual pede cautela; limite superior $> 100\%$ indica *overshoot* possível.

Ano	ADE_y (mm)	ADE_{IW} (mm)	LSIF rec. (%)		corr. (mm)	[IC 95 %]	Classifier	
			ponto	IC _{block} 95 %			AUC	cov. (%)
2021	7,58	5,70	61,6	[43,7; 79,3]	1,88	[1,33; 2,42]	0,754	50,7
2022	4,75	4,62	59,0	[9,2; 115,2] †	0,13	[0,02; 0,26]	0,647	29,4
2023	5,21	4,72	71,8	[43,8; 109,2]	0,49	[0,30; 0,75]	0,657	31,4
2024	4,50	4,24	—	—	—	—	0,612	22,4
2025	5,26	4,75	69,3	[57,2; 79,0]	0,51	[0,42; 0,58]	0,710	41,9

Tabela 2: Recovery individual por feature (LSIF marginal).

Feature	2021 (%)	2023 (%)	2025 (%)	ESS médio
accel_p99	57,1	52,6	51,7	0,55
accel_p90	54,0	51,3	51,1	0,57
accel_mean	43,0	47,0	49,5	0,68
speed_p99	17,2	36,1	40,1	0,84
speed_p90	15,8	34,4	38,0	0,85
speed_mean	7,9	24,7	27,4	0,91
turn_p90	3,9	0,2	0,0	0,97
turn_mean	5,3	0,9	0,0	0,96

absoluta é positivo até em 2022 ($\geq 0,02$ mm): a reponderação aproxima o ADE de 2019 de forma estatisticamente distinguível de zero mesmo com 6 blocos. O classifier confirma o sinal de covariate shift em todos os anos ($\text{AUC} \in [0,61; 0,75]$, $p < 10^{-3}$), ordena os anos por intensidade (2021 mais severo; 2024 mais brando, coerente com a ausência de excesso) e não depende de estimação de razão de densidades. A fração não recuperada ($\approx 30\text{--}40\%$) é concept drift residual mais ruído amostral.

Decomposição por feature. Reestimando o LSIF com cada feature isolada (Tabela 2), **accel_p99** lidera consistentemente nos três anos com excesso significativo; as features de giro têm recovery residual ($< 5\%$). O ranking é estável entre temporadas: a SSL passou a exibir dinâmica de aceleração mais agressiva, e esse é o principal vetor de degradação do modelo.

8 Adaptação ao drift

Com a evidência de que o excesso é majoritariamente covariate (Tabela 1), quatro famílias de estratégias de adaptação foram avaliadas sob um protocolo conservador comum: regime antigo = 2019, dados novos = 2022–2025 (500 trajetórias/jogo), com a edição virtual de 2021 excluída por ser um *outlier* anômalo (Seção 3); encoder congelado com 2 camadas do decoder ajustáveis, $\text{lr} = 10^{-5}$, 5 épocas. A métrica de esquecimento é o `cat_ratio`: a fração de trajetórias do regime antigo que pioram após o ajuste (menor é melhor). A Tabela 3 e a Figura 4 consolidam os números; a seguir destacamos o mecanismo de cada estratégia.

Fine-tuning e EWC. O fine-tuning ingênuo produz *catastrophic interference* severo — sem o protocolo conservador, o `cat_ratio` atinge 0,82 já na primeira época. O EWC [15] tenta mitigá-lo somando ao custo a regularização $\frac{\lambda}{2} \sum_i F_i (\theta_i - \theta_{A,i}^*)^2$, onde F_i é a diagonal da Informação de Fisher (importância de cada parâmetro para o regime de 2019). O achado, porém, é que o ganho não vem do Fisher: um sweep de $\lambda \in \{0, 50, \dots, 10^7\}$ mantém o `cat_ratio` em $\sim 0,46$ ao longo de **8 ordens de grandeza** — a regularização é inerte porque a diagonal é numericamente pequena ($F_i \approx 10^{-7}$, consistente com um decoder já convergido). A proteção contra o esquecimento vem da taxa de aprendizado baixa e do congelamento, não do termo de Fisher.

Replay. Misturar ao fine-tuning um buffer de *replay* do regime original (r = razão replay/novos) melhora as três métricas de forma consistente, com bom compromisso em $r = 0,5$: reduz o `cat_ratio` abaixo do controle sem replay (0,438 vs. 0,457) e, ao mesmo tempo, baixa o ADE nos dois regimes, atingindo o menor ADE nos dados novos da tabela (4,760 mm; Tabela 3). O ganho é modesto — o ajuste conservador já limita o esquecimento —, mas mensurável, na direção certa e a custo trivial. É a base recomendada para adaptação mais profunda (retreino do encoder com replay).

Adaptação dirigida pelo diagnóstico. Se o drift é covariate e dominado pela cauda de aceleração, é natural tentar *dirigir* a adaptação por esse diagnóstico. Três variantes foram testadas no mesmo protocolo: (i) *replay ponderado por importância*, com buffer amostrado proporcionalmente a $\hat{w}(x) = p_{\text{novo}}(x)/p_{\text{antigo}}(x)$ (LSIF sobre as features cinemáticas das janelas); (ii) *fine-tuning seletivo*, restrito ao top-50 % dos dados novos por aceleração de cauda — a região onde $p(x)$ de fato mudou; (iii) a combinação de ambos. O resultado separa as duas formas de dirigir a adaptação (Tabela 3). A curadoria por *reponderação* do replay é ligeiramente benéfica: o replay IW alcança o menor `cat_ratio` (0,417) e o menor ADE no regime antigo (4,404 mm) da tabela, superando o replay uniforme por margem pequena (*seed* único, portanto sem afirmar significância). Já a curadoria por *seleção dura* da cauda é prejudicial: o fine-tuning seletivo por aceleração *piora* o esquecimento acima até do controle sem replay (0,467, o pior da tabela). O mecanismo é instrutivo: a cauda é justamente o subconjunto mais distante do regime de 2019, e treinar exclusivamente nela desloca mais os pesos — o corpo

Tabela 3: Estratégias de adaptação sob o protocolo conservador comum ($\text{lr}=10^{-5}$, encoder congelado, 2 camadas do decoder, 5 épocas), com regime antigo = 2019 e dados novos = 2022–2025 (a edição virtual de 2021 é excluída como *outlier*). **cat_ratio**: fração do regime antigo (2019) que piora após o ajuste (menor = melhor). Modelo original, sem adaptação: ADE 4,584 mm no regime antigo (2019) e 4,965 mm nos dados novos. EWC: mediana do platô $\lambda \in [50; 10^7]$. Em negrito, o melhor de cada coluna. As três últimas linhas são dirigidas pelo diagnóstico covariate/accel (em azul na Figura 4).

Estratégia	cat_ratio ↓	ADE antigo (mm)	ADE novos (mm)
FT conservador ($r = 0$)	0,457	4,480	4,762
EWC (platô λ)	0,457	4,481	4,817
Replay uniforme ($r = 0,5$)	0,438	4,439	4,760
Replay IW	0,417	4,404	4,761
Seletivo accel	0,467	4,526	4,811
Seletivo + replay IW	0,449	4,441	4,800

inalterado da distribuição, que a seleção descarta, funciona como âncora implícita contra a interferência; a reponderação, ao contrário, preserva esse corpo e apenas reforça a cauda relevante. A leitura consolidada: o diagnóstico covariate é valioso para *monitorar* (Seção 9), *explicar* o excesso (Tabela 1) e *ponderar* o replay, mas descartar o corpo da distribuição pela seleção dura da cauda é contraproducente — a rota efetiva é o replay (uniforme ou reponderado) com retreino mais profundo do encoder.




Figura 4: Estratégias de adaptação sob o mesmo protocolo (azul = variantes dirigidas pelo diagnóstico covariate/accel). (a) Esquecimento (`cat_ratio`; barra de erro = platô do sweep de λ do EWC; linha pontilhada = controle sem replay). (b) ADE após a adaptação nos dois regimes, com o modelo original como referência (linhas tracejadas). O replay lidera — reponderar o buffer por importância (replay IW) atinge o menor esquecimento —, enquanto a seleção dirigida pela cauda de aceleração aumenta a interferência em vez de reduzi-la.

9 Detecção online de drift

A camada operacional responde à pergunta 4 sobre o stream de 288k trajetórias (ordenado por ano, jogo e trajetória). Um detector é avaliado pela tríade padrão [10,11]: FAR_{2019} , alarmes por mil trajetórias no ano de treino, onde não há drift (teto de admissibilidade 0,20/1k); *cobertura*, os anos de 2021–2025 com ao menos um alarme; e *latência* do primeiro alarme após cada fronteira de ano. Para eliminar o viés de otimizar e reportar métricas no mesmo stream, a calibração segue validação cruzada 2-fold *por jogos*: metade dos jogos de cada ano seleciona a configuração do ADWIN [12] em uma grade de 96 combinações,² e a outra metade, intocada pela seleção, é avaliada uma única vez. Todos os números são *out-of-sample*, com IC de Wilson 95 %.

Detector primário (erro do modelo). O sinal por trajetória é normalizado por z-robusto local (mediana/MAD em janela de 200 trajetórias), e essa escolha é a condição de viabilidade do detector: sobre o sinal bruto, *nenhuma* das 96 configurações é admissível, em nenhum dos folds, e as 21 suavizações convencionais testadas (médias móveis, EWMA, Holt, Savitzky–Golay) *umentam* a FAR, por introduzirem autocorrelação que viola a hipótese i.i.d. do ADWIN (Figura 5a). Sobre o ADE normalizado, a família vencedora é estável entre folds ($\delta = 10^{-4}$, janelas 1 000/5 000): FAR_{2019} de 0,042/1k (IC [0,007; 0,236], cobertura 5/5) no fold A e 0,125/1k ([0,043; 0,368], 4/5) no fold B — 9/10 anos-fold cobertos, com latência de 0,2–1,5 jogo. O protocolo importa: a configuração que a seleção *in-sample* escolheria mantém $\text{FAR} \approx 0$, mas cobre apenas 2–3/5 anos fora da amostra — o holdout não apenas valida, muda a recomendação.

² Confiança δ , janelas mínima e máxima e *cooldown*; seleção lexicográfica por cobertura $\rightarrow \text{FAR} \rightarrow \text{razão sinal-ruído}$.




Figura 5: Detecção online sob holdout 2-fold por jogos (métricas no split de teste). (a) O stream do fold A: o ADE bruto sobe entre temporadas (topo), o z-robusto local devolve um sinal estacionário — o que o ADWIN de fato lê (meio) — e o rug marca os alarmes das três camadas (base); em 2019 não há drift, logo todo alarme ali é falso. (b) Compromisso de cada camada: falsos alarmes contra cobertura anual; faixa sombreada = região admissível ($\leq 0,20/1k$); em cinza, as features dominadas. (c) Latência do primeiro alarme por ano-fold: a aceleração antecipa o detector de erro em 8/10 casos.

Vigilância dirigida pelo diagnóstico. Se o covariate shift é dominado pela aceleração de cauda (Tabela 2), as próprias features da janela observada — disponíveis sem inferir o modelo e sem esperar os 15 passos futuros que o ADE exige — deveriam carregar o sinal de drift. O mesmo protocolo aplicado a quatro sinais cinemáticos confirma a previsão: a admissibilidade fora da amostra reproduz o ranking da decomposição por feature, com `accel_p95` à frente ($FAR = 0,25\text{--}0,29/1k$, cobertura 5/5 nos dois folds) e as demais entre 0,29 e 0,79/1k.³ Nenhuma feature isolada é admissível — a cinemática varia naturalmente dentro de 2019 —, mas o canal de aceleração *antecipa* o de erro em 8/10 anos-fold (Figura 5c). No extremo oposto, a conjunção $AND(ADE, accel_p95)$ com janela de coincidência $W = 200$ zera os falsos alarmes nos dois folds ($IC [0; 0,16]/1k$), ao custo de cobertura (2–3/5). O diagnóstico da Seção 7, que não se converte

³ Usa-se p95, e não o p99 dominante na Tabela 2, porque a janela observada contém apenas 29 amostras de aceleração.

Tabela 4: Arquitetura de detecção em camadas — métricas no split de teste (folds A/B). Todos os sinais com z-robusto $w=200$; configuração de cada detector selecionada por fold na calibração.

Camada	Sinal	FAR/1k (A/B)	Cobertura	Lat. (jogos)	Ação
Primária	ADE seq2seq	0,042 / 0,125	5/5 / 4/5	0,2–1,5	retreinar
Vigilância	accel_p95	0,292 / 0,250	5/5 / 5/5	0,1–1,1	monitorar
Confirmação	AND(ADE, accel)	0,000 / 0,000	3/5 / 2/5	—	confirmar
Corroborador	ADE Kalman	0,167 / 0,083	5/5 / 5/5	—	redundância

em curadoria amostral (Seção 8), converte-se em arquitetura de monitoramento (Tabela 4).

Ressalvas e resultados negativos. A FAR por trajetória assume trajetórias $\sim$ i.i.d. em 2019, e a autocorrelação é real ($\rho_1 = 0,54$). Um teste por permutação ($B = 200$ sobre o bloco de 2019) mostra que a violação é conservadora: embaralhar as trajetórias dentro dos jogos *zera* os falsos alarmes em todas as réplicas — a dependência serial infla a FAR estimada, logo a admissibilidade não é artefato dela. Entre as alternativas, o Page-Hinkley [13] agregado por janelas atinge FAR = 0, mas detecta apenas o salto de 2021 (validador de mudança abrupta, não monitor), e o KSWIN [14] é inadmissível em todas as configurações (FAR $\geq 0,438/1k$). Por fim, um resultado negativo estrutural: conjugar detectores de *escalas temporais distintas* (ADWIN por trajetória $\times$ Page-Hinkley por janela) é inviável, pois o par de alarmes mais próximo dista $\Delta_{\min} = 214 > W$; alinhar as escalas (dois ADWIN por trajetória) reduz $\Delta_{\min}$ a 3 e produz a camada de confirmação acima. A limitação é da combinação de escalas, não da conjunção em si.

10 Discussão

Os resultados respondem às quatro perguntas da Introdução em cinco mensagens (pergunta 1 $\rightarrow$ mensagens 1–2; pergunta 2 $\rightarrow$ 3; pergunta 3 $\rightarrow$ 4; pergunta 4 $\rightarrow$ 5).

1. O drift é real, gradual e entra pela cauda. O ADE do seq2seq cresce nos anos pós-2019 (Figura 1) — em dados de composição de liga constante (Divisão A) — com excesso em tendência crescente em 2022–2025, além do salto da edição virtual de 2021. A forma da distribuição indica que o regime novo aparece primeiro como cauda (2021) e se incorpora ao corpo do erro nos anos seguintes.

2. O benchmark cinemático degrada mais. O aumento relativo do erro do Kalman supera o do seq2seq em praticamente todos os anos: robustez relativa maior do modelo neural, sem imunidade ao drift.

3. O drift é majoritariamente covariate, dominado por aceleração de cauda. A recovery LSIF de 59–72% — robusta a truncamento de pesos e à transformação de razão relativa, e validada pelo classifier two-sample test

($p < 10^{-3}$) — indica que a maior parte do excesso é explicável por covariate shift, com `accel_p99` liderando a decomposição por feature de forma estável entre temporadas. A fração não recuperada ($\approx 30\text{--}40\%$) sugere concept drift residual.

4. O esquecimento catastrófico é controlável, mas não pelo EWC.

Sob o regime antigo restrito a 2019 (2021 excluído como outlier), o `cat_ratio` cai de 0,82 para 0,46 com ajuste conservador; o sweep de λ em 8 ordens de grandeza mostra que a regularização de Fisher é inerte nesta arquitetura. O replay melhora esquecimento e adaptação simultaneamente, com o ótimo no replay ponderado por importância (`cat_ratio` 0,417), estabelecendo a direção para adaptação mais profunda. Já a seleção *dura* pela cauda de aceleração piora o esquecimento: treinar apenas na região que mais mudou amplia a interferência, e o corpo inalterado da distribuição funciona como âncora. O valor do diagnóstico covariate está no monitoramento, na explicação do excesso e na *ponderação* do replay — não na seleção dura de amostras.

5. Detecção operacional é viável na granularidade certa — e o diagnóstico vira arquitetura. Na granularidade per-game (36 pontos), nenhum método formal detecta; no stream per-trajetória com normalização robusta, o ADWIN sobre o erro atinge FAR, cobertura e latência operacionais *fora da amostra* (holdout por jogos) — e a validação muda a recomendação, pois a configuração selecionada in-sample não replica a cobertura. A admissibilidade dos monitores de feature reproduz o ranking do covariate shift (aceleração > velocidade), o canal de aceleração antecipa o de erro em 8/10 anos-fold, e a conjunção erro/aceleração zera os falsos alarmes observados — o AND só é inviável entre escalas temporais distintas.

Frente a Steuernagel e Máximo [1], o avanço está em deslocar a pergunta: não *se* o seq2seq supera o benchmark em um recorte fixo, mas *como esse ganho evolui* quando a distribuição se afasta do treino — e o que fazer a respeito (adaptação e alarme operacional).

Limitações. (i) A Divisão B não está representada nos dados; as conclusões valem para a Divisão A. (ii) São 6 jogos por ano: os ICs por bloco são largos, a incerteza honesta da FAR (via n_{eff}) é maior que a nominal, e os ICs de Wilson do holdout cruzam o teto de admissibilidade — afirmar admissibilidade com 95% de confiança exigiria mais jogos de 2019. (iii) O ADE é single-mode; modelos multimodais exigiriam $\min\text{-ADE}_K$ [17,18]. (iv) O z-robusto assume drift gradual: sob mudança abrupta, a normalização local absorveria parte do sinal. (v) A fração de concept drift residual não é isolada por feature — pode incluir covariate shift em features não medidas. (vi) A edição de 2021 foi realizada em simulação: seu salto de erro mistura a lacuna simulação-real com o drift sazonal, e as conclusões de tendência gradual apoiam-se em 2022–2025.

11 Conclusão

Este artigo caracterizou, quantificou e operacionalizou o problema de data drift em um modelo seq2seq de predição de trajetórias na RoboCup SSL. Há evidên-

cia clara de degradação temporal — excesso de ADE em tendência crescente em 2022–2025, além do salto da edição virtual de 2021 —, maior sensibilidade do benchmark de Kalman, e drift majoritariamente covariate dominado por `accel_p99` — 59–72 % do excesso explicável por reponderação (LSIF), estimativa robusta a truncamento de pesos e à transformação de razão relativa, e validada por classifier two-sample test independente.

Na resposta ao drift, duas contribuições práticas: (i) a adaptação leve controla o esquecimento (`cat_ratio` 0,82 $\rightarrow$ 0,46, com regime antigo restrito a 2019 e 2021 excluído como outlier), a regularização EWC é inerte em 8 ordens de grandeza de λ , e um buffer de replay melhora esquecimento e adaptação simultaneamente — com ótimo no replay ponderado por importância (`cat_ratio` 0,417) — a base para adaptação mais profunda, enquanto a seleção *dura* pela cauda de aceleração piora o esquecimento; (ii) uma arquitetura de detecção em camadas validada por holdout 2-fold por jogos: detector primário sobre o erro (ADWIN + z-robusto; FAR_{2019} de 0,04–0,13/1k fora da amostra, cobertura 9/10 anos-fold, latência 0,2–1,5 jogo), canal de vigilância *model-free* sobre `accel_p95` — o vetor diagnosticado do drift, que antecipa o alarme de erro em 8/10 anos-fold — e conjunção erro/aceleração com zero falsos alarmes observados. A taxa de falsos alarmes é robusta à dependência serial do stream, e o resultado negativo do AND entre escalas temporais distintas delimita como combinar detectores em streams de erro de modelos de trajetória.

Agradecimentos

Ivan Yamasaki agradece o apoio do ITAEx e do Nubank, no âmbito do Programa de Iniciação Científica em Inteligência Artificial do ITA (2025–2026).

Referências

1. Steuernagel, L., Máximo, M. R. O. A.: Trajectory Prediction for SSL Robots Using Seq2seq Neural Networks. In: Eguchi, A., Lau, N., Paetzel-Prümann, M., Wani-chanon, T. (eds.) RoboCup 2022: Robot World Cup XXV. LNCS, vol. 13561, pp. 27–38. Springer, Cham (2023). doi:10.1007/978-3-031-28469-4_4
2. Bahdanau, D., Cho, K., Bengio, Y.: Neural Machine Translation by Jointly Learning to Align and Translate. In: 3rd International Conference on Learning Representations (ICLR) (2015)
3. Kalman, R. E.: A New Approach to Linear Filtering and Prediction Problems. Journal of Basic Engineering **82**(1), 35–45 (1960)
4. Kingma, D. P., Ba, J.: Adam: A Method for Stochastic Optimization. In: 3rd International Conference on Learning Representations (ICLR) (2015)
5. Sugiyama, M., Nakajima, S., Kashima, H., von Büna, P., Kawanabe, M.: Direct importance estimation with model selection and its application to covariate shift adaptation. In: Advances in Neural Information Processing Systems (NIPS) (2008)
6. Sugiyama, M., Kawanabe, M.: Machine Learning in Non-Stationary Environments: Introduction to Covariate Shift Adaptation. MIT Press (2012)

7. Kanamori, T., Hido, S., Sugiyama, M.: A least-squares approach to direct importance estimation. *Journal of Machine Learning Research* **10**, 1391–1445 (2009)
8. Yamada, M., Suzuki, T., Kanamori, T., Hachiya, H., Sugiyama, M.: Relative density-ratio estimation for robust distribution comparison. *Neural Computation* **25**(5), 1324–1370 (2013). doi:10.1162/NECO_a_00442
9. Lopez-Paz, D., Oquab, M.: Revisiting Classifier Two-Sample Tests. In: 5th International Conference on Learning Representations (ICLR) (2017). arXiv:1610.06545
10. Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., Bouchachia, A.: A survey on concept drift adaptation. *ACM Computing Surveys* **46**(4), 1–37 (2014). doi:10.1145/2523813
11. Lu, J., Liu, A., Dong, F., Gu, F., Gama, J., Zhang, G.: Learning under concept drift: a review. *IEEE Transactions on Knowledge and Data Engineering* **31**(12), 2346–2363 (2019). doi:10.1109/TKDE.2018.2876857
12. Bifet, A., Gavaldà, R.: Learning from time-changing data with adaptive windowing. In: *Proceedings of the 2007 SIAM International Conference on Data Mining (SDM)*, pp. 443–448 (2007). doi:10.1137/1.9781611972771.42
13. Page, E. S.: Continuous Inspection Schemes. *Biometrika* **41**(1–2), 100–115 (1954). doi:10.1093/biomet/41.1-2.100
14. Raab, C., Heusinger, M., Schleif, F.-M.: Reactive Soft Prototype Computing for Concept Drift Streams. *Neurocomputing* **416**, 340–351 (2020). doi:10.1016/j.neucom.2020.01.119
15. Kirkpatrick, J., Pascanu, R., Rabinowitz, N., et al.: Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences* **114**(13), 3521–3526 (2017). doi:10.1073/pnas.1611835114
16. Alahi, A., Goel, K., Ramanathan, V., Robicquet, A., Fei-Fei, L., Savarese, S.: Social LSTM: Human trajectory prediction in crowded spaces. In: *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 961–971 (2016). doi:10.1109/CVPR.2016.110
17. Salzmann, T., Ivanovic, B., Chakravarty, P., Pavone, M.: Trajectron++: Dynamically-feasible trajectory forecasting with heterogeneous data. In: *European Conference on Computer Vision (ECCV)* (2020). arXiv:2001.03093
18. Yuan, Y., Weng, X., Ou, Y., Kitani, K.: AgentFormer: Agent-aware transformers for socio-temporal multi-agent forecasting. In: *IEEE/CVF International Conference on Computer Vision (ICCV)* (2021). arXiv:2103.14023
19. Gu, T., Chen, G., Li, J., Lin, C., Rao, Y., Zhou, J., Lu, J.: Stochastic Trajectory Prediction via Motion Indeterminacy Diffusion. In: *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (2022). arXiv:2203.13777